

H6: schattingsmethodes	
6.1 methode van de momenten	
6.1.1 principe van de methode	
def: methode van de momenten	<p>Een parameter a wordt afgeschat door te stellen dat het verwachte gemiddelde gelijk moet zijn aan het effectief geobserveerde gemiddelde uit de steekproef</p> $E_X(\hat{a}) = \langle X \rangle = \int x P(x; \hat{a}) dx = \bar{x}$
stelling: fout op \hat{a} 6.1.1	<p>fout op \hat{a} is gegeven door:</p> $V(\hat{a}) = \left(\frac{d\hat{a}}{d\bar{x}} \right)^2 \frac{1}{N(N-1)} \sum_{i=1}^N (x_i - \bar{x})^2$
6.1.2 generalisatie	
def: algemene MM	<p>er is een set van N metingen x_i en een te fitten fistributie $P(x; \theta)$</p> <ul style="list-style-type: none"> > bevat k onbekende parameters $\theta = \theta_1, \dots, \theta_k$ > construeer k lineair onafhankelijke functies $g_j(x)$ > deze $g_j(x)$ zijn functies van meetgegevens met een verwachtingswaarde: $\langle g_j(x) \rangle = \int g_j(x) P(x; \vec{\theta}) dx \equiv e_j(\vec{\theta})$ <p>de methode van de momenten voor θ wordt dan gegeven door:</p> $\begin{aligned} e_1(\vec{\theta}) &= \frac{1}{N} \sum_{i=1}^N g_1(x_i) \\ &\vdots \\ e_k(\vec{\theta}) &= \frac{1}{N} \sum_{i=1}^N g_k(x_i) \end{aligned}$
functies van momenten	<p>Een mogelijke keuze voor $g_j(x)$ zijn de veeltemen x^1, x^2, \dots, x^k</p> <ul style="list-style-type: none"> > verwachtingswaarde is het j-de moment van x: $\langle g_j(x) \rangle = \langle x^j \rangle$ <p>we kunnen echter ook orthonormale functies kiezen</p> <ul style="list-style-type: none"> > bvb machten van sin, cos of polynomen
stelling: covariantie van schatters	<p>schatters worden uit eenzelfde set van N waarnemingen gehaald</p> <ul style="list-style-type: none"> > er zal een zekere correlaties tss de schatters zijn > bepaal via de covariantiematrix: $\text{cov}(\hat{\theta}_i, \hat{\theta}_j) = \sum_{l,m} \frac{\partial \hat{\theta}_i}{\partial \hat{e}_l} \frac{\partial \hat{\theta}_j}{\partial \hat{e}_m} \text{cov}(\hat{e}_l, \hat{e}_m)$ <p>de schatter van de covariantie tss de verwachtingswaardefuncties is:</p> $\widehat{\text{cov}}(\hat{e}_l, \hat{e}_m) = \frac{1}{N(N-1)} \sum_{i=1}^N (g_l(x_i) - \bar{g}_l)(g_m(x_i) - \bar{g}_m)$

6.2 maximum (log)Likelihood	
6.2.1 principe van de methode	
principe vd maximum likelihood MLLH	<p>voor een steekproef $\mathbf{x} = \{x_1, \dots, x_N\}$ is de maximum likelihood schatter \hat{a} die waarde van a waarbij de likelihood maximaal word</p> <p>> deze was gedefinieerd is als:</p> $\mathcal{L}(a : \vec{x}) = \prod_{i=1}^N P(x_i; a)$ <p>in praktijk is het makkelijker om de logaritmes de maximaliseren:</p> $\ln \mathcal{L}(a : \vec{x}) = \sum_{i=1}^N \ln P(x_i; a)$ <p>Het maximum vinden we dan:</p> $\left. \frac{d \ln \mathcal{L}}{da} \right _{a=\hat{a}} = 0$
6.2.2 Gauss paramater schatten	
MLLH op Gauss	<p>naam aan dat er $\{x_i\}$ metingen zijn van dezelfde grootheid met versch. precisie</p> <p>> ie: x_i is getrokken uit een Gauss met gekende standaardafwijking σ_i</p> <p>> waarvoor we nu een schatting voor μ willen maken</p> <p>De waarschijnlijkheidsfunctie:</p> $P(x_i; \mu, \sigma_i) = \frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma_i^2}}$ <p>zodat de logaritme van de likelihood gelijk wordt aan</p> $\ln \mathcal{L} = \sum_i \left(-\ln(\sqrt{2\pi\sigma_i^2}) \right) - \sum_i \frac{(x_i - \mu)^2}{2\sigma_i^2}$ <p>en afleiden naar μ om het maximum te vinden geeft:</p> $\sum_i \frac{(x_i - \hat{\mu})}{\sigma_i^2} = 0$ $\hat{\mu} = \frac{\sum (x_i / \sigma_i^2)}{\sum (1 / \sigma_i^2)}$ <p>> x_i waarden uitgemiddeld met elk een gewicht σ_i^{-2} en correct genormeerd</p> <p>> dit hebben we al gevonden voor het gewogen gemiddelde</p>
MLLH op Gauss met onbekende σ	<p>Stel nu dat ook σ onbekend is</p> <p>> we moeten afleiden naar beide grootheden:</p> $\begin{cases} \mu \rightarrow \sum_i \frac{(x_i - \hat{\mu})}{\hat{\sigma}^2} = 0 \\ \sigma \rightarrow -\frac{N}{\hat{\sigma}} + \frac{\sum (x_i - \hat{\mu})^2}{\hat{\sigma}^3} = 0 \end{cases}$ <p>we vinden voor μ hetzelfde</p> <p>> we vinden $\hat{\mu} = \bar{x}$, zoals tevoren.</p> <p>> dan hebben we de vgl: $\hat{\sigma}^2 = \frac{1}{N} \sum (x_i - \bar{x})^2$</p>
6.2.3 eigenschappen van de MLLH methode	
stelling: consistentie van MLLH	MLLH schatters zijn meestal consistent, maar niet altijd
stelling: parametertransformatie en MLLH	<p>MLLH schatters zijn invariant onder parameter transformaties:</p> $\widehat{f(a)} = f(\hat{a})$

6.2.4 asymptotische limiet en MBV

bias in asymptotische limiet	Voor $N \rightarrow \infty$ wordt elke consistente schatter onbevooroordeeld > bias van consistente MLLH verdwijnt in asymptotische limiet
efficiëntie in asymptotische limiet	<p>Veronderstel dat de echte waarde voor a a_0 is > de schatter \hat{a} voldoet aan:</p> $\left. \frac{d \ln \mathcal{L}}{da} \right _{a=\hat{a}} = 0$ <p>in een Taylorreeks rond a_0:</p> $\left. \frac{d \ln \mathcal{L}}{da} \right _{a_0} + (\hat{a} - a_0) \left. \frac{d^2 \ln \mathcal{L}}{da^2} \right _{a_0} + \mathcal{O}(\hat{a}^2) = 0$ <p>$(\hat{a} - a_0)$ wordt klein voor grote N > enkel eerste twee termen bekijken</p> <p>Echter nu, \hat{a} is niet identiek aan a_0 > want afgeleide van $\ln \mathcal{L}$ bij a_0 wijkt af van 0 door statistische fluctuaties van gegevens:</p> $\left. \frac{d \ln \mathcal{L}}{da} \right _{a_0} \neq 0$ <p>we weten ook dat:</p> $\left\langle \frac{d \ln \mathcal{L}}{da} \right\rangle = 0$ <p>Vermits de afgeleide bekomen wordt als som van N onafh. termen zegt het Centraal Limiet theorema ons dat de verdeling Gaussisch is</p>
variantie van $d \ln \mathcal{L}$	<p>We vinden:</p> $V \left(\left. \frac{d \ln \mathcal{L}}{da} \right _{a_0} \right) = \left\langle \left(\left. \frac{d \ln \mathcal{L}}{da} \right _{a_0} \right)^2 \right\rangle - \underbrace{\left\langle \left. \frac{d \ln \mathcal{L}}{da} \right _{a_0} \right\rangle^2}_0 = - \left\langle \left. \frac{d^2 \ln \mathcal{L}}{da^2} \right _{a_0} \right\rangle \quad (6.10)$ <p>De verwachtingswaarden worden uitgewerkt voor $a = a_0$ en is dus de tweede term van de variantie gelijk aan nul.</p>
variantie van $(\hat{a} - a_0)$	<p>De Taylorreeks geeft ons dat $(\hat{a} - a_0)$ evenredig is met $d \ln \mathcal{L} / da$ > wordt ook beschreven door Gauss met gemiddelde:</p> $\langle \hat{a} - a_0 \rangle = \left\langle \frac{d \ln \mathcal{L}}{da} \right\rangle = 0$ <p>nu dus:</p> $V(\hat{a} - a_0) = \left(\frac{d(\hat{a} - a_0)}{d \ln \mathcal{L}} \right)^2 V \left(\frac{d \ln \mathcal{L}}{da} \right) = - \left\langle \frac{d^2 \ln \mathcal{L}}{da^2} \right\rangle / \left(\left. \frac{d^2 \ln \mathcal{L}}{da^2} \right _{a_0} \right)^2$
Variantie bij grote N	<p>In de limiet van grote N convergeren verwachtingswaarden naar de echte waarde,</p> $\left\langle \frac{d^2 \ln \mathcal{L}}{da^2} \right\rangle = \left. \frac{d^2 \ln \mathcal{L}}{da^2} \right _{a_0}$ <p>zodat we de verwachtingswaarde in de teller mogen vervangen door zijn waarde bij a_0. Daardoor valt één van de factoren in de noemer weg, zodat we voor de variantie van \hat{a} vinden:</p> $V(\hat{a}) = \sigma_{\hat{a}}^2 = - \frac{1}{\left(\left. \frac{d^2 \ln \mathcal{L}}{da^2} \right _{a_0} \right)} = - \frac{1}{\left\langle \frac{d^2 \ln \mathcal{L}}{da^2} \right\rangle} \quad (6.11)$ <p>hetgeen precies de MVB is.</p>

6.2.5 fouten op de MLLH schatters

stelling: fout op MLLH schatter	<p>Voor elke onbevooroordeelde efficiënte MLLH schatter kan de fout geëvalueerd worden:</p> $V(\hat{a})^{-1} = - \left. \frac{d^2 \ln \mathcal{L}}{da^2} \right _{a=\hat{a}}$						
stelling: waarden van log-likelihood	$\ln \mathcal{L}(a) = \ln \mathcal{L}_{\max} - \frac{(a - \hat{a}(\vec{x}))^2}{2\sigma^2}$ <p>Bij het punt 1σ weg van de piek is $\ln \mathcal{L}$ met 0.5 verminderd</p> <table> <tr> <td>2σ</td><td>2</td></tr> <tr> <td>3σ</td><td>4.5</td></tr> <tr> <td>...</td><td>...</td></tr> </table>	2σ	2	3σ	4.5
2σ	2						
3σ	4.5						
...	...						

vor van de log-likelihood	<p>Een beetje herwerken van de formule vinden we:</p> $\ln \mathcal{L}_{\max} - \ln \mathcal{L} = \frac{A}{2} [\hat{a}(\vec{x}) - a]^2$ <p>De log-likelihood is dus een parabool (Fig.6.3). Exponentiëren leidt tot</p> $\mathcal{L}(\vec{x}; a) = \mathcal{L}_{\max} e^{\frac{A}{2} [a - \hat{a}(\vec{x})]^2}$
asymmetrische fouten	<p>Als N niet groot genoeg is, is de Likelihood ftie geen Gauss en log-likelihood geen parab.</p> <p>> bekijk waar de functie 0.5 gezakt is</p> <p>> dit zal niet meer perfect symmetrisch liggen</p> <p>> asymmetrische fouten, notatie vb:</p> $a = 0.21^{+0.29}_{-0.27}$
6.2.6 meerdere parameters	
MLLH voor meerdere parameters	<p>Veralgemeen alles tot nu toe gewoon voor een meerdimensionaal geval</p> <p>> we zoeken nu dus:</p> $\frac{\partial \ln \mathcal{L}(x_1, \dots, x_N; a_1, \dots, a_k)}{\partial a_j} = 0 \quad \forall j = 1, \dots, k$ <p>> zelfde voor invariantie</p> <p>> likelihood ftie is een meerdimensionale Gauss</p>
stelling: covariantiematrix	<p>We vinden:</p> $\sigma_{\hat{a}_j}^{-2} = - \left\langle \frac{\partial^2 \ln \mathcal{L}}{\partial a_j^2} \right\rangle \quad \text{cov}^{-1}(a_i, a_j) = - \left\langle \frac{\partial^2 \ln \mathcal{L}}{\partial a_i \partial a_j} \right\rangle = - \left. \frac{\partial^2 \ln \mathcal{L}}{\partial a_i \partial a_j} \right _{a=\hat{a}}$
vorm van likelihood functie	<p>voor grote N in 2D vormt ze een 2D Gauss:</p> $\ln \mathcal{L}(a_1, a_2) = (\ln \mathcal{L})_{\max} - \frac{1}{2(1-\rho^2)} \left[\left(\frac{a_1 - \hat{a}_1}{\sigma_{\hat{a}_1}} \right)^2 + \left(\frac{a_2 - \hat{a}_2}{\sigma_{\hat{a}_2}} \right)^2 - 2\rho \left(\frac{a_1 - \hat{a}_1}{\sigma_{\hat{a}_1}} \right) \left(\frac{a_2 - \hat{a}_2}{\sigma_{\hat{a}_2}} \right) \right]$ <p>waarin $\rho = \text{cov}(\hat{a}_1, \hat{a}_2) / (\sigma_{\hat{a}_1} \sigma_{\hat{a}_2})$ de correlatiecoëfficiënt voor a_1 en a_2 is. Het contour van $\ln \mathcal{L}(a_1, a_2) = \ln \mathcal{L}_{\max} - 0.5$ is dus gegeven door:</p> $\frac{1}{1-\rho^2} \left[\left(\frac{a_1 - \hat{a}_1}{\sigma_{\hat{a}_1}} \right)^2 + \left(\frac{a_2 - \hat{a}_2}{\sigma_{\hat{a}_2}} \right)^2 - 2\rho \left(\frac{a_1 - \hat{a}_1}{\sigma_{\hat{a}_1}} \right) \left(\frac{a_2 - \hat{a}_2}{\sigma_{\hat{a}_2}} \right) \right] = 1$ <p>Dit is een ellips met als centrum de MLLH schatters (\hat{a}_1, \hat{a}_2) die een hoek ϕ maakt met de a_1-as:</p> $\tan 2\phi = \frac{2\rho\sigma_{\hat{a}_1}\sigma_{\hat{a}_2}}{\sigma_{\hat{a}_1}^2 - \sigma_{\hat{a}_2}^2}$ <p>Merk in het bijzonder op dat de raaklijnen aan de ellips parallel met de assen de ellips snijden bij $a_1 = \hat{a}_1 \pm \sigma_{\hat{a}_1}^2$ en $a_2 = \hat{a}_2 \pm \sigma_{\hat{a}_2}^2$.</p>
6.2.7 opmerkingen bij Maximum Likelihood methode	
opmerkingen	<p>- 'maximum' betekend niet 'meest waarschijnlijke' waarde</p> <p>positief:</p> <ul style="list-style-type: none"> - voor grote N heeft \hat{a} een waarsch.verdeling die onbevooroordeeld is en Gaussisch rond de echte waarde van a met variantie gegeven door de MVB > heel goede schatter - er gaat geen info verloren door gegevens samen te nemen in bins <p>negatief:</p> <ul style="list-style-type: none"> - voor kleine N vertoont de MLLH een bias - je moet de vorm van de ouderdistributie kennen - de vgl van $d\ln\mathcal{L}/da$ is niet altijd op te lossen
6.2.8 maximum likelihood en Monte Carlo	
max likelihood en monte carlo	<p>in sommige gevallen is likelihood niet analytisch op te lossen</p> <p>> bereken numeriek</p> <p>> veronderstel dat de schatter efficiënt en onbevooroordeeld is</p> <p>> gebruik Monte Carlo om MLLH uit te breiden</p>

6.2.9 uitgebreide maximum likelihood

<p>uitgebreide maximum likelihood</p> <p>EML</p>	<p>Standaard is de waarschijnlijkheidsdichtheid genormeerd:</p> $\int P(x; a) dx = 1$ <p>laat deze voorwaarde echter los</p> <p>> neem een functie Q, zonder een vaststaande normering:</p> $\int Q(x; a) dx = \nu$ <p>> handig voor experimenten waarbij aantal gebeurtenissen a priori bekend is</p> <p>Een bepaalde Q(x;a) voorspeld dus v elementen in een gebied</p> <p>> verm. de likelihood met de Poisson dat N evenementen observeert als gemiddelde v:</p> $e^{-\nu} \frac{\nu^N}{N!}$ <p>dan is de log-likelihood:</p> $\begin{aligned} \ln \mathcal{L} &= \sum \ln P(x_i; a) - \nu + N \ln \nu \\ &= \sum \ln(\nu P(x_i; a)) - \nu \\ &= \sum \ln Q(x_i; a) - \nu \end{aligned}$ <p>een toename in normering van Q zal de likelihood doen stijgen</p> <p>> waargenomen evenement wordt meer waarschijnlijk</p>
<p>eigenschappen van EML</p>	<p>Zelfde eigenschappen als MLLH</p>
<p>covariantiematrix EML</p>	$\text{cov}(a_i, a_j)^{-1} = - \left\langle \frac{\partial^2 \ln \mathcal{L}}{\partial a_i \partial a_j} \right\rangle = - \int \frac{\partial \ln Q}{\partial a_i} \frac{\partial \ln Q}{\partial a_j} Q(x; a) dx$ <p>> zelfde als MLLH op een factor N na</p>

6.3 kleinste kwadraten	
gebruik kleinste kwadraten	<p>Je hebt twee variabelen x en y en:</p> <ol style="list-style-type: none"> 1. een aantal exact gekende x waarden, 2. een corresponderende verzameling y waarden, gemeten met een nauwkeurigheid σ_y, 3. een functie $f(x; \vec{\theta})$ die de waarde van y voorspelt voor om het even welke x; de vorm van deze functie is bekend maar bevat onbekende parameters $\vec{\theta}$ die je probeert te bepalen. <p>>> om onbekende parameters te bepalen uit een aantal gegevens</p>
6.3.1 principe van de methode	
def: kleinste kwadraten	<p>Je minimaliseert het (gewogen) kwadratisch verschil tss een groep van N metingen (x_i, y_i) en de voorspelde waarden $f(x_i; \vec{\theta})$:</p> $\chi^2 = \sum_{i=1}^N \left[\frac{y_i - f(x_i; \vec{\theta})}{\sigma_i} \right]^2$ <p>> laat de parameters die je wilt bepalen variëren > voorspelde waarden worden zodanig aangepast dat je dicht bij waarneming uitkomt > kwadrateren zorgt voor een meer uitgesproken verschil</p>
werking van KK	<p>Uit een set van N precieze waarden $x = \{x_1, \dots, x_N\}$ met hiervoor $y = \{y_1, \dots, y_N\}$ met σ_i nauwkeurigheid op y_i</p> <p>> methode om een parameter a van een functie $f(x; a)$ te schatten die de echte waarde van y voorspelt voor om het even welke x</p> <p>> kies dan die waarde van a die de kleinste χ^2 geeft</p> <p>> als f afgeleid kan worden, kan deze kleinste χ^2 gevonden worden via:</p> $\frac{d\chi^2}{da} = \sum_i \frac{2}{\sigma_i^2} \frac{df(x_i; a)}{da} [y_i - f(x_i; a)] = 0$ <p>de bekomen schatting \hat{a} op a heeft een fout die we kunnen uitrekenen</p> <p>> nl: \hat{a} wordt gegeven als functie van y_i deze een fout σ_i hebben</p> <p>> formule voor propagatie van fouten geeft de fout op \hat{a}</p>
KK in meerdere dimensies	<p>de functie hangt nu af van een $\vec{\theta} = \{\theta_1, \dots, \theta_k\}$ ipv a</p> <p>> er zijn k gekoppelde vgl'n in k onbekenden:</p> $\frac{\partial \chi^2}{\partial \theta_i} = 0 \quad \forall i = 1, \dots, k$
KK vanuit maximum likelihood	<p>als de metingen y Gaussische verdeeld zijn</p> <p>> neem aan dat de y gegeven worden door een fctie f van x die afh. is v parameter a</p> <p>> functie geldt evenwel enkel voor de ideale y</p> <p>> onze metingen wijken daarvan af door de resolutie</p> <p>Centraal Limiet Theorema: verdeling vd gemeten y rond de ideale waarde is Gaussisch</p> <p>> waarschijnlijkheid om bepaalde y_i te hebben voor gegeven x_i:</p> $P(y_i; a) = \frac{1}{\sigma_i \sqrt{2\pi}} e^{-\frac{(y_i - f(x_i; a))^2}{2\sigma_i^2}}$ <p>de log-likelihood vd volledig steekproef is dus:</p> $\ln \mathcal{L} = -\frac{1}{2} \sum_{i=1}^N \left[\frac{y_i - f(x_i; a)}{\sigma_i} \right]^2 - \sum_{i=1}^N \ln \sigma_i \sqrt{2\pi}$ <p>om de likelihood te maximaliseren moet de volgende geminimaliseerd worden:</p> $\sum_{i=1}^N \left[\frac{y_i - f(x_i; a)}{\sigma_i} \right]^2$ <p>wat niet anders dan de KK is</p>

6.3.2 een rechte fitten

toepassing KK	aanpassen van een rechte is meest voorkomende toepassing > metingen y_i hebben allemaal een fout σ en liggen op een lijn $y=mx+c$
$y=mx$ fitten	<p>we moeten χ^2 minimaliseren door m aan te passen:</p> $\chi^2 = \sum_{i=1}^N \left[\frac{y_i - mx_i}{\sigma_i} \right]^2 \quad (6.18)$ <p>Dit afleiden naar m geeft:</p> $\frac{d\chi^2}{dm} = \sum -2x_i \frac{y_i - mx_i}{\sigma_i^2}$ <p>Als alle σ_i gelijk zijn wordt dit een gemeenschappelijke factor die buiten de som kan gebracht worden, hetgeen leidt tot:</p> $\frac{-2}{\sigma^2} \sum (x_i y_i - mx_i^2)$ <p>Voor de kleinste kwadraten schatting van de helling, \hat{m} is deze som gelijk aan 0 en dus:</p> $\sum x_i y_i = \hat{m} \sum x_i^2$
stelling: \hat{m}	<p>De KK schatting van m is:</p> $\hat{m} = \frac{\overline{xy}}{\overline{x^2}}$ <p>met nauwkeurigheid</p> $V(\hat{m}) = \sum_{i=1}^N \left(\frac{d\hat{m}}{dy_i} \right)^2 \sigma_i^2 = \sum_{i=1}^N \left(\frac{x_i}{N\overline{x^2}} \right)^2 \sigma^2$ <p>> dus:</p> $V(\hat{m}) = \frac{\sigma^2}{N\overline{x^2}}$
stelling: fitten van $y=mx+c$	<p>als alle σ_i gelijk zijn, dan:</p> $\hat{m} = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - \bar{x}^2} = \frac{\text{cov}(x, y)}{V(x)} \quad \text{en} \quad \hat{c} = \bar{y} - \hat{m}\bar{x} = \frac{\overline{x^2}\bar{y} - \bar{x}\overline{xy}}{\overline{x^2} - \bar{x}^2}$ <p>de eerste uitdrukking voor \hat{c} geeft aan dat de lijn door het zwaartepunt (\bar{x}, \bar{y}) gaat</p>
stelling: fouten op schatters	<p>fouten op schatter worden gegeven door</p> $V(\hat{m}) = \frac{1}{N(\overline{x^2} - \bar{x}^2)} \sigma^2 \quad \text{en} \quad V(\hat{c}) = \frac{\overline{x^2}}{N(\overline{x^2} - \bar{x}^2)} \sigma^2$ <p>De covariantie en correlatiecoëfficiënt tussen de schatters \hat{m} en \hat{c} wordt gegeven door :</p> $\text{cov}(\hat{m}, \hat{c}) = \frac{-\bar{x}}{N(\overline{x^2} - \bar{x}^2)} \sigma^2 \quad \rho_{\hat{m}, \hat{c}} = \frac{\text{cov}(\hat{m}, \hat{c})}{\sqrt{V(\hat{m})V(\hat{c})}} = -\frac{\bar{x}}{\sqrt{\overline{x^2}}}$
stelling: χ^2 zonder \hat{m} en \hat{c}	<p>De χ^2 kan berekend worden zonder de voorafgaande kennis van \hat{m} en \hat{c} > zonder de som van de afwijkingen te nemen:</p> $\chi^2 = N \frac{V_y}{\sigma^2} (1 - \rho_{x,y}^2)$
stelling: systematische fout	Een systematische fout y heeft geen invloed op de helling van \hat{m} maar wordt (kwadratisch) opgeteld bij de fout op het intercept \hat{c}
χ^2 bij ongelijke σ_i	<p>als de σ_i niet allen gelijk zijn dan:</p> $\chi^2 = \sum_i \frac{1}{\sigma_i^2} (y_i - mx_i - c)^2$ <p>> geeft dezelfde vgl'n voor \hat{m} en \hat{c} maar:</p> <p>\bar{x} en \bar{y} zijn de gewogen gemiddelden met gewichtsfunctie $w_i = \sigma_i^{-2}$</p> <p>de normering wordt dan door het totale gewicht W gegeven, niet door N:</p> $W = \sum_{i=1}^N \sigma_i^{-2}$ <p>op precies dezelfde manier moet de grootte σ^2 vervangen worden door:</p> $\overline{\sigma^2} = \frac{1}{W} \sum_{i=1}^N w_i \sigma_i^2 = \frac{1}{W} \sum_{i=1}^N \sigma_i^{-2} \sigma_i^2 = \frac{N}{W}$

Extrapolatie van y	<p>Voor een gegeven X > de voorspelling Y is gelijk aan:</p> $\hat{m}X + \hat{c}.$ <p>De fout hierop:</p> $V(Y) = V(\hat{c}) + X^2 V(\hat{m}) + 2X \text{cov}(\hat{m}, \hat{c})$ <p>> we willen echter deze laatste term vermijden > als $\bar{x} = 0$ valt deze term weg > je moet je later niet herinneren om hem mee te nemen > $Y = \hat{m}(X - \bar{X}) + \hat{c}'$ >> geeft de ongecorrleerde schattingen voor \hat{m} en \hat{c}'.</p>
stelling: fout op Y	<p>de fout op de geëxtrapoleerde waarde Y is:</p> $V(Y) = \frac{\sigma^2}{N(\bar{x}^2 - \bar{x}^2)}(X - \bar{x})^2 + \frac{\sigma^2}{N}$
6.3.3 gebinde gegevens	
principe van bins	<p>Bij grote steekproeven zijn er veel computaties nodig > oplossing: neem gegevens samen in bins</p> <p>veronderstel er zijn N evenementen met waarschijnlijkheidsfunctie P(x;a) > deze zijn gesorteerd in intervallen van 1 tot N_b > interval j is gecentreerd op punt x_j, heeft breedte B_j en bevat n_j elementen</p> <p>ideaal verwachte aantal elementen in een bin j is f_j = NB_jP(x_j;a) > eigenlijke aantal wordt beschreven door Poisson statistiek > variantie is gelijk aan gemiddelde > de totale χ^2 gesommeerd over alle intervallen is:</p> $\chi^2 = \sum_j \frac{(n_j - f_j)^2}{f_j}$ <p>of vereenvoudigd:</p> $\chi^2 \approx \sum_j \frac{(n_j - f_j)^2}{n_j}$
6.3.4 de χ^2-verdeling	
def: χ^2	<p>= kwadraat van verschil in waargenomen y_i^w en theoretische y_i^t gewogen volgens de fout op de waarnemingen σ_i</p> $\chi^2 = \sum_i \frac{(y_i - f(x_i))^2}{\sigma_i^2} = \sum_{i=1}^N \left(\frac{y_i^w - y_i^t}{\text{verwachte fout}} \right)^2$
def: aantal vrijheidsgraden	= aantal punten N in de som min het aantal variabelen k dat aangepast is om χ^2 te minimaliseren
betekenis van χ^2	<p>- als de functie goed overeenkomt zal χ^2 klein zijn - als χ^2 te klein is, betekent dit dat de fout σ op de metingen fout ingeschat is</p>
st: waarschijnlijkheidsdichtheid	<p>de waarsch.dichtheid van χ^2 met n vrijheidsgraden is:</p> $P(\chi^2; n) = \frac{2^{-n/2}}{\Gamma(n/2)} \chi^{n-2} e^{-\chi^2/2}$ <p>waarbij $\Gamma(x)$ de standaard gamma functie is.</p>
stelling: som van χ^2	<p>Als 2 variabelen een χ^2 verdeling volgen met N₁ en N₂ metingen > dan wordt de som van de 2 beschreven door een χ^2 met N₁+N₂ metingen</p>

6.3.5 fouten op x en y

casestudy: fouten op x en y

Veronderstel dat er fouten zijn op zowel x als y:

1: fout op x = fout op y = σ

2: x en y verschillende nauwkeurigheid

geval 1: gelijke fouten

fit een rechte lijn en pas de maximum likelihood toe

> een gemeten punt B kan afkomstig zijn van eender welk punt A op de ideale rechte

> waarschijnlijkheidsdichtheid hiervoor is:

$$\begin{aligned} P(A \rightarrow B) &= \frac{1}{2\pi\sigma^2} e^{-\frac{(x_A - x_B)^2}{2\sigma^2}} e^{-\frac{(y_A - y_B)^2}{2\sigma^2}} \\ &= \frac{1}{2\pi\sigma^2} e^{-\frac{r^2}{2\sigma^2}} \\ &= \frac{1}{2\pi\sigma^2} e^{-\frac{u^2}{2\sigma^2}} e^{-\frac{h^2}{2\sigma^2}} \end{aligned}$$

om de totale waarschijnlijkheid te vinden dat B afkomstig is van A, integreren over alle u:

$$P(B) = \frac{1}{2\pi\sigma^2} \int e^{-\frac{u^2}{2\sigma^2}} e^{-\frac{h^2}{2\sigma^2}} du = \frac{1}{2\pi\sigma^2} \sqrt{2\pi\sigma^2} e^{-\frac{h^2}{2\sigma^2}}$$

h is de loodrechte afstand van het punt tot de lijn

ie: van het gemeten punt tot het punt C

> C is het meest waarschijnlijke punt op de rechte

om χ^2 te vormen: sommeer alle gekwadeerde afstanden tss B en overeenkomstige C

> uit gelijkvormige driehoeken uit de figuur vinden we h:

$$h_i = \frac{y_i - (mx_i + c)}{\sqrt{1 + m^2}}$$

dus we vinden voor χ^2

$$\chi^2 \propto \sum_i \frac{(y_i - mx_i - c)^2}{1 + m^2}$$


- afleiden naar c levert de formule $\bar{y} = \hat{m}\bar{x} + \hat{c}$

- afleiden naar m levert:

$$\hat{m} = A \pm \sqrt{A^2 + 1} \quad \text{met} \quad A = \frac{V(y) - V(x)}{2\text{cov}(x, y)}$$

> twee oplossingen voor \hat{m} staan loodrecht op elkaar

> één geeft de beste oplossing, de ander de slechtste



geval 2: ongelijke fout

Herschaal de variabelen zodat ze wel dezelfde fout hebben:

$$y' = \frac{y}{\sigma_y}, \quad x' = \frac{x}{\sigma_x}$$

na transformatie terug naar oorspronkelijke x en y vinden we:

$$\hat{m} = \frac{\sigma_y}{\sigma_x} (A \pm \sqrt{A^2 + 1}) \quad \text{met} \quad A = \frac{\sigma_x^2 V(y) - \sigma_y^2 V(x)}{2\sigma_x \sigma_y \text{cov}(x, y)}$$

6.3.6 lineaire kleinste kwadraten en matrices

variabelen in vectorvorm

- \mathbf{a} is een vector met k parameters a_1, \dots, a_k
 - \mathbf{y} is vector met alle y_i
 - \mathbf{f} is vector met alle $f(x_i; \mathbf{a})$
- >> allen vectoren hebben N elementen

χ^2 in matrixnotatie

we weten:

$$\chi^2 = \sum_i \sum_j [y_i - f(x_i; \mathbf{a})] V_{ij}^{-1} [y_j - f(x_j; \mathbf{a})]$$

of dus:

$$\chi^2 = (\tilde{\mathbf{y}} - \tilde{\mathbf{f}}) \mathbf{V}^{-1} (\mathbf{y} - \mathbf{f})$$

als er onafhankelijke metingen zijn, dan is \mathbf{V} diagonaal:

$$V_{ij} = \sigma_i^2 \delta_{ij} \quad V_{ij}^{-1} = \frac{\delta_{ij}}{\sigma_i^2}$$

- >> leidt nu af naar elke a_r en stel deze gelijk aan 0
> we krijgen n vgl'n waaruit we $\hat{\mathbf{a}}$ kunnen halen

stelling: $\hat{\mathbf{a}}$ en $\mathbf{V}(\hat{\mathbf{a}})$

$$\hat{\mathbf{a}} = (\tilde{\mathbf{C}} \mathbf{V}^{-1} \mathbf{C})^{-1} \tilde{\mathbf{C}} \mathbf{V}^{-1} \mathbf{y}$$

de nauwkeurigheid wordt gegeven door de covariantiematrix

$$\mathbf{V}(\hat{\mathbf{a}}) = (\tilde{\mathbf{C}} \mathbf{V}(\mathbf{y})^{-1} \mathbf{C})^{-1}$$

- > \mathbf{V} is een NxN matrix
 \mathbf{C} is een rechthoekige matrix met N rijen en n kolommen
 > \mathbf{C} is de matrix bestaande uit alle C_{ir} : $C_{ir} = c_r(x_i)$

6.3.7 niet-lineaire kleinste kwadraten

niet-lineaire kleinste kwadraten

indien $f(x; \mathbf{a})$ niet lineair, gebruik een iteratieve methode

voor een eerste gok \mathbf{a}^0 zijn de gradiënten voor onafhankelijke metingen:

$$\left. \frac{\partial \chi^2}{\partial a_r} \right|_{\mathbf{a}=\mathbf{a}^0} = g_r(\mathbf{a}^0) = \sum_i -\frac{2}{\sigma_i^2} [y_i - f(x_i; \mathbf{a}^0)] \frac{\partial f(x_i; \mathbf{a}^0)}{\partial a_r}$$

Je wilt een minimum raken, en dus een increment $\delta \mathbf{a}$ vinden waarvoor geldt :

$$g_r(\mathbf{a}^0 + \delta \mathbf{a}) = \left. \frac{\partial \chi^2}{\partial a_r} \right|_{\mathbf{a}=\mathbf{a}^0 + \delta \mathbf{a}} = 0 \quad \forall r$$

Je doet dit door een ontwikkeling van $\frac{\partial \chi^2}{\partial a_r}$ in een Taylor reeks, waarbij je enkel de nulde en eerste orde termen behoudt :

$$g_r(\mathbf{a}^0 + \delta \mathbf{a}) \approx g_r(\mathbf{a}^0) + \sum_s \frac{\partial g_r}{\partial a_s} \delta a_s = g_r(\mathbf{a}^0) + \sum_s \frac{\partial^2 \chi^2}{\partial a_r \partial a_s} \delta a_s$$

Noteren we $f(x_i; \mathbf{a}^0)$ voor het gemak als f_i dan:

$$G_{rs} = \frac{\partial^2 \chi^2}{\partial a_r \partial a_s} = \sum_i \frac{-2}{\sigma_i^2} \left[-\left(\frac{\partial f_i}{\partial a_r} \right) \left(\frac{\partial f_i}{\partial a_s} \right) + (y_i - f_i) \left(\frac{\partial^2 f_i}{\partial a_r \partial a_s} \right) \right]$$

Eindelijk vinden we uit de matrix vergelijking :

$$\delta \mathbf{a} = -\mathbf{G}^{-1} \mathbf{g}$$

waarbij de oplossing via iteratie bekomen wordt.

- >> wanneer de g_r klein genoeg worden stopt de iteratie
 > resulterende \mathbf{a} wordt als oplossing genomen

implementatie in python: standaardpakket in software bibliotheek